

PML-Bericht

February 6, 2022

1 Bericht Projektlabor Maschinelles Lernen (PML)

Gruppenmitglied	Matrikelnummer
Christian Singer	2161064
Domenic Gosein	2160647
Lukas Burger	2150580
Maximilian Kürschner	2160331

Dozent: Dr.-Ing. Wei Yap Tan

Fakultät der Informationstechnik

Hochschule Mannheim

Wintersemester 2021/22

1.1 Inhalt

1. Einleitung
2. Das Kalman Filter
3. 1D Radarsensor Experiment
4. 3D Radarsensor Experiment
- ..
- ..
- ..
5. Schlussfolgerung
6. Ausblick
7. Verwendete Literatur
8. Anhang

Wenn Sie diesen Bericht mit Jupyter Notebook ausführen, müssen Sie als erstes folgende Zeilen ausführen, um alle nötigen Module zu importieren.

```
[1]: # Import aller benötigten Module

# Eigene Module
from DataGenerationRadar3D import *
from DBScan import *
```

```

from ui import interactive1DExperiment, interactiveDBScan, interactive3DExperiment

# Externe Module
import numpy as np
import matplotlib.pyplot as plt
from mpl_toolkits.mplot3d import Axes3D
import copy
from collections import deque
from ipywidgets import *
from collections import deque
%matplotlib widget

```

1.2 Einleitung

Nach einer Einführung in maschinelles Lernen, war es unsere Aufgabe das Kalman Filter und den DBSCAN Algorithmus für Daten aus einem 1D und anschließend 3D Radarsensor zu implementieren.

Um ein besseres Verständnis für das Kalman Filter zu erlangen, haben wir uns zunächst mit der Theorie dahinter beschäftigt. Im Zuge dieses Prozesses sind wir auf den α - β -Filter gestoßen. Der α - β -Filter bildet die Grundlage für eine Reihe von Filtern, darunter auch das Kalman Filter. Wir haben uns daher dazu entschlossen, diesen zu Übungszwecken zu implementiert.

```

[2]: class abFilter:
    def __init__(self, x_0, dx, a, b, dt):
        self.x_est = x_0 # initial state value
        self.dx = dx # initial change rate
        self.a = a # a scale factor
        self.b = b # b scale factor
        self.dt = dt # time step

    def step(self, values):
        ests = []
        preds = []
        for z in values:
            # Predict
            x_pred = self.x_est + (self.dx * self.dt)
            preds.append(x_pred)
            self.dx = self.dx
            # Update
            residual = z - x_pred
            self.dx += self.b * (residual)/self.dt
            self.x_est = x_pred + self.a * residual
            ests.append(self.x_est)
        return np.array(ests), np.array(preds)

```

In unserem Beispiel verwenden wir den Filter dazu, das Körpergewicht einer Person vorherzusagen.

Unser Filter verwendet dazu folgende Parameter: * x_0 als initialen Zusatzendwert (in unserem Fall das Anfangsgewicht) * dx als initiale Änderungsrate des Gewichts z. B. +0.5 kg/Tag * a als Faktor für die Veränderung der Gewichtsmessung * b als Faktor für die Änderungsrate des Gewichts * dt für das Zeitintervall

sowie `values` für unsere Messwerte.

Nachdem der α - β -Filter initialisiert wurde, führt er folgende Schritte aus:

1. Berechnung der Vorhersage im nächsten Zeitintervall basierend auf aktuellem Schätzwert, Änderungsrate und Zeitintervall
2. Berechnen der Differenz aus aktuellem Messwert und Vorhersage
3. Anpassung der neuen Änderungsrate mit Faktor b , des Restwerts aus Schritt 2 und dem Zeitintervall
4. Berechnung des neuen Schätzwerts mittels Vorhersage, Faktor a und Restwert

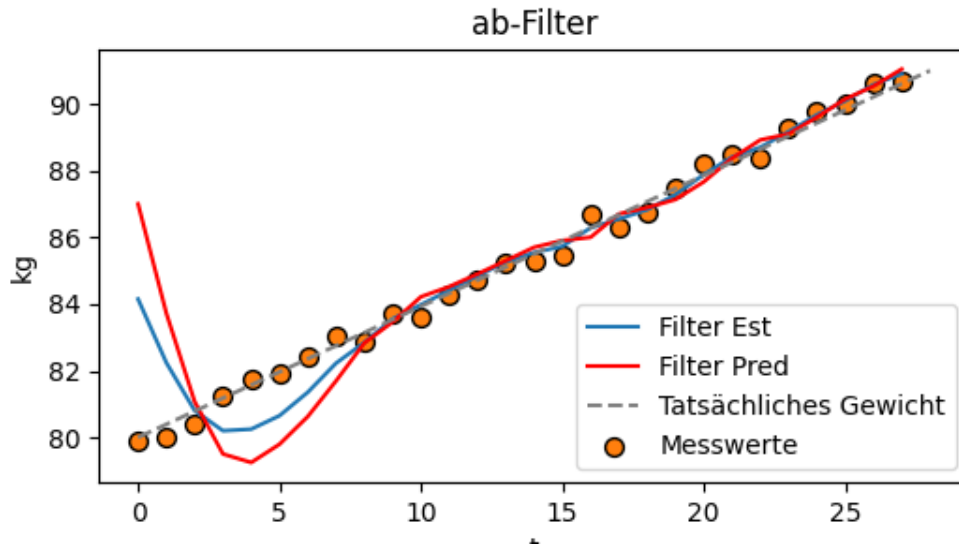
Um den Filter zu testen haben wir mittels einer Funktion 14 Messwerte generiert und diese an den Filter übergeben. Zur Initialisierung haben wir zudem 86 kg, einen Änderungsrate von +1 kg/Tag, einen α -Wert von 0.4 und einen β -Wert von 0.2 und einen Zeitintervall von 1 übergeben. Auf passende Werte für a und b sind wir durch ausprobieren gestoßen.

```
[3]: # Daten: Körpergewichte über n Tage verteilt gemessen
count = 28
def data_generator(x_0, dx, count, noise_factor):
    return [x_0 + dx * i + np.random.randn() * noise_factor for i in
    →range(count)]

gewichte = data_generator(79.9, 0.4, count, 0.3) # kg
#print(gewichte)
zeitabstaende = [i for i in range(28)] # n Tage
print()
# Initialisierung und Ausführung des ab-Filters
gewicht_filter = abFilter(x_0=86, dx=1, a=0.4, b=0.2, dt=1.)
pr = gewicht_filter.step(values=gewichte)

# Ploten der Filter Ergebnisse im Vergleich zu den den echten Werten
fig, ax = plt.subplots(figsize=(6, 3))
ax.plot(pr[0], label='Filter Est')
ax.plot(pr[1], label='Filter Pred', color='r')
ax.scatter(zeitabstaende, gewichte, s=50, facecolor='C1', edgecolor='k',
    →label='Messwerte')
ax.plot([0,count], [80., 91.], label='Tatsächliches Gewicht', linestyle='--',
    →color='grey')
ax.set_xlabel('t')
ax.set_ylabel('kg')
ax.set_title("ab-Filter")
ax.legend()
```

[3]: <matplotlib.legend.Legend at 0x7f67245e99a0>



Die von uns gewählte initiale Schätzung von 86 kg war mit Absicht sehr hoch gewählt. Wir sehen daher einen großen Ausschlag zu Beginn, schließlich benötigt der Filter einige Iterationen, um sein Werte anzupassen, so dass der Filter zum Ende hin eine deutlich bessere Schätzung ausgiebt.

1.3 Das Kalman Filter

Das Kalman Filter ist ein Algorithmus, der anhand einer Reihe von Messungen über eine gewisse Zeit unbekannte Variablenwerte eines Systems schätzt. Dabei versucht das Filter Unsicherheiten durch statistisches Rauschen und den Einbezug eines zu Grunde liegenden physikalischen Modells zu reduzieren.

In unserem Fall versuchen wir mit das Kalman Filter die Position eines Objekts erst im eindimensionalen Raum, dann in einem dreidimensionalen Raum vorherzusagen,. Die Messwerte liefert uns dabei eine Radarsensor Simulation.

Die Klasse `KalmanFilter` implementiert das Kalman Filter und besteht aus zwei Methoden. Über die `__init__(self, s_hat, transition_model, H, Q, R)` Methode kann das Kalman Filter mit folgenden Parametern initialisiert werden: * `s_hat` ist die Position des Objekts im Raum (x, y, z Koordianten) * `P_hat` ist die Kovarianz des Zustands * `model/transition_model` ist das zu Grunde liegende physikalische Modell * `H` ist die Messfunktion * `Q` beschreibt das Prozessrauschen * `R` beschreibt das Messrauschen

Nach der Initialisierung kann die `step(self,z)` Funktion mit den Messwerten `z` aufgerufen werden, um den Kalman Algorithmus auszuführen.

```
[4]: class KalmanFilter:
      # Initialisierung von Kalman Filter
      def __init__(self, s_hat, transition_model, H, Q, R):
          self.s_hat = s_hat
```

```

self.P_hat = np.eye(len(s_hat)) * 100
self.model = transition_model
self.H = H # Measurement Function
self.Q = Q # Process Noise
self.R = R # Measurement Noise.
self.kgain = []

def step(self, z):
    # Prediction
    s_hat_p = self.model @ self.s_hat
    P_hat_p = self.model @ self.P_hat @ self.model.T + self.Q
    # Calculate Kalman Gain
    K = P_hat_p @ self.H.T @ np.linalg.inv(self.H @ P_hat_p @ self.H.T +
    ↪self.R)
    self.kgain.append(K)
    # Update covariance of estimation error
    self.P_hat = self.P_hat - K @ self.H @ self.P_hat
    # Improve estimate
    e_m_p = z - self.H @ s_hat_p
    self.s_hat = s_hat_p + K @ e_m_p
    return self.s_hat

```

Im Detail führt die `step(self,z)` Methode dann folgende Schritte nacheinander aus:

1. Vorhersage der neuen Position
2. Berechnung der Kovarianz des Zustands
3. Berechnung des Kalman Gain
4. Aktualisierung der Kovarianz des Zustands
5. Verbesserung der Schätzung

Zum Schluss wird die neu geschätzte Position zurückgegeben.

1.4 1D Radarsensor Experiment

Die Simulation für den 1D Radarsensor gibt uns die Wahl zwischen fünf verschiedenen Bewegungsarten: Static, Constant Velocity, Constant Acceleration, Sinus und Triangle, sowie die Möglichkeit einen Sporadic Error zu den Sensordaten hinzuzufügen. Zudem lassen sich an dieser Stelle die Sensor Eigenschaften anpassen.

```
[5]: ## insert Lukas Teil hier
```

1.5 3D Radarsensor Experiment

Um die Ergebnisse und den Vorteil des DBScan Algorithmus zu verdeutlichen, haben wir das Experiment in zwei Abschnitte unterteilt. Im ersten Abschnitt betrachten wir die unterschiedlichen Ergebnisse des Experiments nur mit dem Kalman Filter, im zweiten Abschnitt dann mit vorgelegtem DBScan.

1.5.1 3D Experiment ohne DBScan

Um den Aufbau des Experiments zu zeigen, initialisieren wir an dieser Stelle zunächst einen Kalman Filter mit Werten, die sich durch unsere Experimente als gut erwiesen haben.

Unser **Übergangsmodell** ist wie folgt aufgebaut und basiert auf dem im Skript gegebenen physikalischen Modell der gleichmäßig beschleunigten Bewegung.

Bei einer *measurementRate* von 100 Hz sieht das zugrunde liegende Gleichungssystem demnach wie folgt aus:

$$\begin{pmatrix} 1 & 0.01 & 0.01/2 \\ 0 & 1 & 0.01 \\ 0 & 0 & 0.01 \end{pmatrix}$$

```
[6]: transition_model = np.array([[1, 0.01, 0.01/2],
                                [0, 1, 0.01 ],
                                [0, 0, 0.01 ]])
print(transition_model)
```

```
[[1.  0.01 0.005]
 [0.  1.   0.01 ]
 [0.  0.   0.01 ]]
```

Mit der **Q-Matrix** fügen wir unser Prozessrauschen hinzu, in unserem Fall hat sich 0.05 als guter Wert für alle drei Parameter erwiesen:

```
[7]: Q = np.diag([0.09, 0.09, 0.09])
print(Q)
```

```
[[0.09 0.  0.  ]
 [0.  0.09 0.  ]
 [0.  0.  0.09]]
```

Durch Recherche (Quelle einfügen) sind wir darauf gestoßen, dass es eine gängige Methode ist die **R-Matrix** mit folgendem Wert für das Messrauschen des Radarsensor zu initialisieren:

```
[8]: R = np.diag([rangeAccuracy**2])/3
print(R)
```

```
[[0.00083333]]
```

Zum Schluss initialisieren wir die **H-Matrix** wie folgt:

```
[9]: H = np.array([[1., 0., 0.]])
print(H)
```

```
[[1. 0. 0.]]
```

Die Einstellungen für unser *Target* belassen wir bei den uns gegebenen Werten:

```
[10]: path = [[0,5,0],
              [0,5,0.5],
              [1,5,1],
              [1,5,0.5],
              [0.5, 2, 0.1]]

vel = 3 * numpy.ones((1,5))
vel[0,2] = 1

InitialPosition = numpy.array([-1,5,0])

opt = {
    'InitialPosition' : InitialPosition,
    'Path' : numpy.array(path).transpose(),
    'Velocities' : vel
}

x = Target(opt)

targets = [x]
```

Lediglich bei den Einstellungen des Radarsensors nehmen wir kleiner Anpassungen vor, um die *False Detections* zu reduzieren haben wir einen zusätzlichen Parameter zu den Optionen des 3D Radarsensors hinzugefügt. Der neue Parameter `falseDetectionsRange` bestimmt die *Range* der *False Detections* im *DataGenerationRadar3D* Skript.

```
[11]: optRadar = {
        'Position' : numpy.array([0,0,0.5]),
        'OpeningAngle' : numpy.array([120,90]), # [Horizontal, Vertical]
        'FalseDetection': True,
        'falseDetectionsRange' : 10
    }
sensor = RadarSensor(optRadar)
```

Anschließend iterieren wir mit nachfolgender Schleife über die *Detections* des 3D Radarsensors und plotten das Ergebnis:

```
[12]: Detections = np.array([0,0,0,0])
i = 0
pred = []

getNext = True
while(getNext == True):

    for target in targets:
        target.Step(1/sensor.opt['MeasurementRate'])
        getNext = getNext & ~target.reachedEnd
```

```

dets = sensor.Detect(targets)
# Exclude radialVelocity for the moment. (todo: include it.)
for det in dets:
    #det = det[:-1]
    Detections = np.vstack((det, Detections))

s0 = np.vstack((Detections[0,:-1], np.zeros((2,3))))

if i == 0:
    f = KalmanFilter(s0, transition_model, H, Q, R)
    pred.append(s0[0,:])

s = Detections[0,:-1].reshape(1,3)
s_hat = f.step(s)
pred = np.vstack((s_hat[0,:], pred))
i += 1

```

In den beiden Abbildungen sehen wir die *Predictions* des Kalman Filter getrennt von den *Detections* der Simulation:

```

[13]: T1 = pred[:-1]

fig = plt.figure(figsize=(8, 4))
ax1 = fig.add_subplot(121, projection='3d')
ax2 = fig.add_subplot(122, projection='3d')

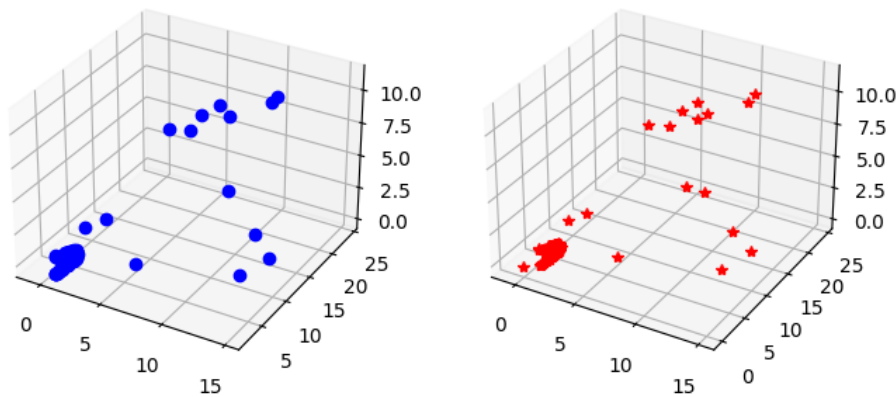
ax1.plot3D(T1[:,0], T1[:,1], T1[:,2], 'bo')
ax2.plot3D(Detections[:,0], Detections[:,1], Detections[:,2], 'r*')

```

```

[13]: [<mpl_toolkits.mplot3d.art3d.Line3D at 0x7f6720c2b8b0>]


```



Legen wir beide zusammen erhalten wir folgenden Plot:

```
[14]: fig = plt.figure()
      ax = plt.axes(projection='3d')
      ax.plot3D(T1[:,0], T1[:,1], T1[:,2], 'bo')
      ax.plot3D(Detections[:,0], Detections[:,1], Detections[:,2], 'r*')
```

```
[14]: [<mpl_toolkits.mplot3d.art3d.Line3D at 0x7f6720b0b550>]
```





In diesem zusammengeführten Plot können wir nun deutlich erkennen wie gut unser Kalman Filter mit seiner aktuellen Initialisierung die Position unseres Objekts vorhersagt. Im folgenden werden wir die einzelnen Parameter des Kalman Filter verändern und das Ergebnis dabei untersuchen.

1.5.2 Verschiede Parameter Werte beim 3D Experiment

Als erstes verändern wir die **Q-Matrix**. Indem wir deren Werte erhöhen und damit mehr Rauschen zum Prozess hinzufügen.

```
Q = np.diag([0.09, 0.09, 0.09])
```



Wie man sehen kann, führt dies zu..

Verändert man die **R-Matrix** wie folgt..

R =

Wie man sehen kann, führt dies zu..

1.5.3 3D Experiment mit DBScan

Der DBSCAN Algorithmus findet vorhandene Cluster in einer Menge an Datenpunkten. Um diese Aufgabe zu erfüllen hat der Algorithmus zwei verstellbare Parameter. Zum einen den Parameter `eps`, der bestimmt in welchem Radius um den Datenpunkt nach Nachbarn gesucht wird, und zum anderen den Parameter `minpts`, der festlegt wie viele Punkte es minimal braucht damit es sich um einen Kernobjekt handelt.

Da sich die gefundenen Cluster mit dem Verstellen der Parameter ändern können müssen diese auf das jeweilige Problem angepasst werden.

Für den DBSCAN wurde eine Klasse erstellt, durch die der Algorithmus mit den beiden zuvor genannten Parametern initialisiert wird. Einmal initialisiert kann man den Algorithmus mit den gesetzten Parametern auf verschiedene Datensätze anwenden.

```
[15]: class DBSCAN():
        def __init__(self, eps=0.5, minpts=5):
            self.eps = eps
            self.minpts = minpts
```

Um die Cluster in einem bestimmten Datensatz zu finden besitzt die DBSCAN Klasse die Funktion `fit(self, X)`. Dabei entspricht `X` dem Datensatz der analysiert werden soll. Innerhalb dieser Funktion wird der DBSCAN Algorithmus auf die Daten aus `X` angewendet und die einzelnen Datenpunkte werden als Kernobjekte, Dichte-erreichbare Objekte und Rauschpunkte kategorisiert.

Für die Bestimmung der Punkte Art wird der Abstand zwischen zwei Punkten benötigt. Um diesen Abstand zu bestimmen wird die Hilfsfunktion `pairwise_sq_distance` erstellt.

```
[16]: def pairwise_sq_distance(X1, X2):
        # Calculate the pairwise distance between all pairs of points from X1 and
        # X2.
        return np.sum(X1**2, axis=1, keepdims=True) - 2*np.matmul(X1, X2.T) + np.
        sum(X2**2, axis=1, keepdims=True).T
```

```
[17]: def fit(self, X):
        dist = pairwise_sq_distance(X, X)
        neighbours = list(map(lambda d: np.arange(d.shape[0])[d < self.eps**2],
        dist))

        # Label all points as outliers initially.
        self.assignment = np.full((X.shape[0],), -1, dtype=int)
        # Find core points.
        # Determine the number of neighbors of each point.
        N_neighbors = np.sum(dist < self.eps**2, axis=1)
        self.assignment[N_neighbors >= self.minpts] = -2

        # Create clusters.
        cluster = 0
        stack = deque()
        for p in range(X.shape[0]):
            if self.assignment[p] != -2:
```

```

        continue

    self.assignment[p] = cluster

    stack.extend(neighbours[p])
    # Expand cluster outwards.
    while len(stack) > 0:
        n = stack.pop()
        label = self.assignment[n]
        # If core point include all points in -neighborhood.
        if label == -2:
            stack.extend(neighbours[n])
            # If not core point (edge of cluster).
        if label < 0:
            self.assignment[n] = cluster

    cluster += 1

DBSCAN.fit = fit

```

Die Funktion `fit` findet die verschiedenen Cluster und speichert diese in der Variable `assignments` ab. Das heißt wenn ich die Methode `fit` aufrufe werden nicht die gefundenen Cluster zurückgegeben. Für diese Aktion existiert die `predict` Methode.

Zusätzlich zu der basis `predict` Funktion gibt es auch die Methode `fit_predict`. Diese ruft zuerst `fit` auf, also findet die Cluster, und danach `predict`, also um die Werte zurückzugeben. Das heißt wenn man den Algorithmus zum ersten mal auf einen Datensatz anwendet und direkt das Ergebnis haben will sollte die Funktion `fit_predict` verwendet werden. Wenn man das Ergebnis des Algorithmus zu einem spätern Zeitpunkt nochmal benötigt muss nur noch `predict` ausgeführt werden. Kurz gesagt kann durch die Aufspaltung von `fit` und `predict` Rechenaufwand reduziert werden.

```

[18]: def predict(self,X):
        return self.assignment

    def fit_predict(self, X):
        self.fit(X)
        return self.assignment

DBSCAN.predict = predict
DBSCAN.fit_predict = fit_predict

```

Um den DBSCAN zu testen haben wir den `make_moons` Datensatz von `scikitlearn` genutzt. Das Ergebnis kann man hier sehen:

```

[19]: from sklearn.datasets import make_moons

X,y = make_moons(100)
model = DBSCAN()
preds = model.fit_predict(X)

```

```

# Either low or high values are good since DBSCAN might switch class labels.
print(f"Accuracy: {round((sum(preds == y)/len(preds))*100,2)}%")

fig= plt.figure(facecolor='w')
ax = plt.axes()
plt.plot(X[:, 0][preds==1], X[:, 1][preds==1], "co")
plt.plot(X[:, 0][preds==0], X[:, 1][preds==0], "ro")


# X contains two features, x1 and x2
plt.xlabel(r"$x_1$", fontsize=20)
plt.ylabel(r"$x_2$", fontsize=20)

# Simplifying the plot by removing the axis scales.
plt.xticks([])
plt.yticks([])

# Displaying the plot.
plt.show()

```

Accuracy: 0.0%



1.5.4 Experiment für den 3D Radarsensor

In diesem Experiment sollen ein oder mehrere Ziele in einem drei dimensionalen Raum getrackt werden. Dafür werden der DBSCAN, zur Zielerkennung und der Kalman-Filter zur Laufbahnvorhersage genutzt.

In dem folgenden Code werden diese Ziele und ihre Laufbahnen angelegt:

```
[20]: # Parameters first target.
path1 = [[0,5,0],
         [0,5,0.5],
         [1,4,1],
         [2,3,2],
         [1,5,3],
         [1,5,0.5],
         [0.5, 2, 0.1]]

vel1 = 3 * np.ones((1,len(path1)))
vel1[0,2] = 1

InitialPosition1 = np.array([-1,5,0])

opt1 = {
    'InitialPosition' : InitialPosition1,
    'Path' : np.array(path1).transpose(),
    'Velocities' : vel1
}

# Parameters second target.
path2 = [[1. , 4. , 1. ],
         [1. , 5. , 1.7],
         [2. , 5. , 1. ],
         [3. , 4. , 2. ],
         [3. , 4. , 1.5],
         [2. , 4. , 2. ]]

vel2 = 2 * np.ones((1,len(path2)))
vel2[0,4] = 0.5

InitialPosition2 = np.array([2,4,1])

opt2 = {
    'InitialPosition' : InitialPosition2,
    'Path' : np.array(path2).transpose(),
    'Velocities' : vel2
}
```

Zusätzlich wird der Radar Sensor initialisiert:

```
[21]: '''
Setup the radar sensor
The radar sensor points always to the direction along the y axis
(see diagram in the note)
'''

optRadar = {
    'Position' : np.array([0,0,0.5]),
    'OpeningAngle' : np.array([120,90]), # [Horizontal, Vertical]
    'FalseDetection': True
}
sensor = RadarSensor(optRadar)
```

Die Bewegung der Ziele findet in einer while-Schleife statt. Dabei wird in jeder Iteration jedes Ziel einen Schritt weiter bewegt. Nachdem ein Schritt durchgeführt wurde versucht der Sensor die Ziele wahrzunehmen und mithilfe des DBSCAN die Ziele zu finden. Die Analyse durch den DBSCAN gibt allerdings erst ab einer in `pt_history` festgelegt Anzahl an Datenpunkten einen Sinn. Sobald das erste mal diese Anzahl erreicht wurde wird der DBSCAN in jeder Iteration auf die letzten `pt_history` Datenpunkte angewendet. Die dabei gefundenen Cluster werden den verschiedenen Zielen aus `labeled` zugeordnet. Existiert das Ziel noch nicht in diesem Dictionary wird es erstellt.

```
[22]: def scan(model, pt_history, targets):
    getNext = True
    detections = np.array([0,0,0,0])
    # Count number of iterations
    i = 0
    labeled = {}

    while(getNext == True):
        i += 1
        for target in targets:
            target.Step(1/sensor.opt['MeasurementRate'])
            getNext = getNext & ~target.reachedEnd

        dets = sensor.Detect(targets)
        for det in dets:
            detections = np.vstack((det, detections))

        if i >= pt_history:
            # First application of DBSCAN.
            clusters = model.fit_predict(detections[:pt_history])
            # Determine number of targets (objects tracked).
            num_objs = set(clusters)

            for j in num_objs:
                # Find index of first occurrence of target j in clusters. This
                ↪ line is needed to filter out false detections
```

```

obj_idx = np.where(clusters == j)[0][0]

if j not in labeled.keys():
    labeled[j] = detections[obj_idx, :-1]

s = detections[obj_idx, :-1].reshape(1,3)
labeled[j] = np.vstack((s, labeled[j]))

return labeled

```

Werden diese dann visualisiert kann man erkennen, dass einige Datenpunkte Ausreißer sind und der Rest Pfade verschiedener Objekte darstellen. Über das folgende Dictionary wird festgelegt welches Objekt welche Farbe bekommen soll (Es sind so viele, denn je nach Einstellung der Parameter werden mehr als die zwei Realen Objekte gefunden).

```

[23]: colors = { -1: 'red', 0: 'green', 1: 'yellow', 2: 'blue', 3: 'purple', 4: 'orange', 5: 'pink', 6: 'black', 7: 'brown' }

```

Um eine gute Einstellung für den DBSCAN zu finden werden zuerst zwei Extreme Einstellungen getestet. Bei der ersten (links) Einstellungen werden die Parameter niedrig und bei der zweiten Einstellung (rechts) hoch initialisiert. Dabei wird die Variable `pt_history` bei einem Wert von konstant 20 belassen (ein Erhöhen dieser Variable entspricht einem Verringern von `minpts` und ein Verringern der Variable entspricht einer Erhöhung von `minpts` (das kann im interaktiven Beispiel am Ende der Sektion überprüft werden)).

```

[24]: model1 = DBSCAN(eps=0.1, minpts=2)
model2 = DBSCAN(eps=1, minpts=10)
# Number of previous measurements to consider for DBSCAN().
pt_history = 20

# Instantiate targets
x = Target(opt1)
y = Target(opt2)

targets = [x, y]

# Plot Trajectories
fig= plt.figure(figsize=(8,6), dpi= 100, facecolor='w')
labeled1 = scan(model1, pt_history, targets)
print(f'Found {len(labeled1.keys())-1} clusters and {len(labeled1[-1])} outlier!')

ax = fig.add_subplot(1, 2, 1, projection='3d')
for label in labeled1.keys():
    T = labeled1[label];
    ax.scatter(T[:,0], T[:,1], T[:,2], c=f'{colors[label]}')

```



```

# Instantiate targets
x = Target(opt1)
y = Target(opt2)

targets = [x, y]

labeled2 = scan(model2, pt_history, targets)
print(f'Found {len(labeled2.keys())-1} clusters and {len(labeled2[-1])} outlier!
      ↪')



# Plot Trajectories
ax = fig.add_subplot(1, 2, 2, projection='3d')
for label in labeled2.keys():
    T = labeled2[label];
    ax.scatter(T[:,0], T[:,1], T[:,2], c=f'{colors[label]}')

# show plot
plt.style.use('classic')
plt.show()

```

Found 6 clusters and 106 outlier!

Found 1 clusters and 107 outlier!



Das Ergebnis dieses Tests ist, das bei beiden Einstellungen etwas nicht stimmt. Bei der ersten zu niedrigen Einstellung werden zu viele Cluster gefunden. Das liegt vermutlich an einem zu niedrigen Wert für `eps`, denn dadurch werden nur die Punkte mit einer so geringen Entfernung einem Cluster zu geordnet => `eps` erhöhen. Ähnliches passiert bei der zweiten Einstellung. Bei dieser kann zwar Objekte in einem größeren Umkreis finden (was auch passiert), aber er braucht deutlich mehr `minPts` bevor diese zu einem Cluster zählen => `minPts` verringern.

Ergebend aus unseren ersten beiden Tests ergibt sich das ein für uns gutes Ergebnis zwischen den beiden Extrema liegen muss. Also `eps` hoch und `minPts` runter (bei der Einstellung von `pt_history` = 20). Durch mehrere Tests der selben Art hat sich die folgende Einstellung für uns als gut ergeben.

```
[25]: model = DBSCAN(eps=0.7, minpts=2)
      # Number of previous measurements to consider for DBSCAN().
      pt_history = 20

      # Instantiate targets
      x = Target(opt1)
      y = Target(opt2)


      targets = [x, y]

      labeled = scan(model, pt_history, targets)
      print(f'Found {len(labeled.keys())-1} clusters and {len(labeled[-1])} outlier!')

      # Plot Trajectories
      fig= plt.figure(figsize=(8,6), dpi= 100, facecolor='w')
      ax = plt.axes(projection='3d')
      for label in labeled.keys():
          T = labeled[label];
          ax.scatter(T[:,0], T[:,1], T[:,2], c=f'{colors[label]}')

      # show plot
      plt.show()
```

Found 2 clusters and 89 outlier!



Wie zu sehen werden die beiden Objekte gut durch den DBSCAN erkannt und die Ausreißer erfolgreich rausgefiltert.

1.6 Interaktiver Teil (Jupyter Notebook)

Um diesen Teil nutzen zu können, muss das Jupyter Notebook im Browser ausgeführt werden

1.6.1 Interaktives Kalman Filter 1D


Text

```
[26]: interactive1DExperiment.plot_interactive_kalaman_filter()
```

Output()

Output()

```
HBox(children=(VBox(children=(HTML(value='<h4>Data settings</h4>'),
↪Dropdown(description='Type:', options=('St...
```




1.6.2 Interaktiver DBScan

In dem folgenden Beispiel können die Parameter `eps`, `minPts` und `ante` verstellt werden um die zu sehen wie die verschiedenen Einstellungen das Ergebnis des DBSCAN beeinflussen.

```
[27]: interactiveDBScan.plot_interactive_dbscan()
```

```
VBox(children=(FloatSlider(value=0.7, continuous_update=False,
    ↳description='$\\epsilon$', max=1.0, min=0.1, re...
```

Output()




1.6.3 Interaktiver Kalman Filter mit DBScan 3D

Text

```
[28]: interactive3DExperiment.plot_3DExperiment()
```

```
VBox(children=(FloatSlider(value=0.2, continuous_update=False,
    ↳description='$\\epsilon$', max=1.0, min=0.1, re...
```

Output()



1.7 Verwendete Literatur

1. Kalman and Bayesian Filters in Python, 2015, Roger R. Labbe

1.8 Anhang

[29]: `# Anhang Code`

[]: